

FIGURE 4.6 – Histogrammes des résidus de reconstruction par la NMF pour 2 patchs normaux (partie supérieure) et 2 patchs inusuels (partie inférieure). Les cadres noirs correspondent aux points qui ont été correctement représentés par le dictionnaire, les cadres bleus aux artéfacts créés par le dictionnaire et les points rouges aux points mal représentés par le dictionnaire. Les résidus peuvent être modélisés par des gaussiennes.

résidus positifs, il s'agit de fixer un seuil pour les déterminer. Ce seuil est défini pour tous les patchs et ne doit donc pas être sensible aux différences d'ordres de grandeur des résidus entre les différents patchs. Nous définissons les seuils de détection à partir des deux mêmes approches définies pour les curvelets.

- Le seuil est défini sur les p-valeurs des tests statistique d'adéquation à la distribution des résidus modélisée par une gausienne.

$$pval^+(Z_{\mathcal{K}_j(f, N_2)}^i) \approx \mathbb{P}_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)} \left(X > R_{NMF}^+(Z_{\mathcal{K}_j(f, N_2)}^i) \right) = 1 - F_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)} \left(R_{NMF}^+(Z_{\mathcal{K}_j(f, N_2)}^i) \right)$$

$\hat{\mu}_j^i$ et $\hat{\sigma}_j^i$ représentent les paramètres des distributions gaussiennes des résidus R_{NMF} . La détection s'effectue alors par comparaison de la p-valeur de chaque point au seuil de détection s_+ .

$$\tilde{Y}_{f, N_2}^i = \mathbf{1} \left\{ pval^+(Z_{\mathcal{K}_j(f, N_2)}^i) \leq s_+ \right\}$$

- Le seuil s_{max} est défini par le mode de la distribution des valeurs extrêmes estimée à partir des n_{max} résidus positifs maximaux.

$$s_{max} = \operatorname{argmax} \left(f_{R_{NMF, n_{max}}^+}^e \right)$$

La détection s'effectue par comparaison des résidus positifs au s_{max} .

$$\tilde{Y}_{f,N_2}^i = \mathbb{1} \left\{ R_{NMF}^+(Z_{\mathcal{K}_j(f,N_2)}^i) \geq s_{max} \right\}$$

Ces approches permettent de définir automatiquement des seuils de détection sur les données. Ces seuils sont calibrés sur la base de validation Ω_{Val} de la base de données \mathcal{B}_1 , les données dont nous disposons d'une annotation de quelques points. Les résultats sont présentés sur la base de test Ω_{Test} de la même base de données. Nous ajoutons un filtrage de voisinage pour peaufiner la détection en considérant qu'un point est inusuel si et seulement si 2 de ses voisins directs \mathcal{V}_{f,N_2} sont inusuels également comme les signatures atypiques correspondent à des raies.

$$\hat{Y}_{f,N_2}^{i,NMF} = \begin{cases} 0 & \text{si } \tilde{Y}_{f,N_2}^i = 0 \\ 0 & \text{si } \tilde{Y}_{f,N_2}^i = 1 \text{ \& } \sum_{k \in \mathcal{V}_{f,N_2}} \tilde{Y}_k^i < 2 \\ 1 & \text{si } \tilde{Y}_{f,N_2}^i = 1 \text{ \& } \sum_{k \in \mathcal{V}_{f,N_2}} \tilde{Y}_k^i \geq 2 \end{cases} \quad (4.12)$$

4.5.3 Calibration des paramètres

Les points de la base de données \mathcal{B}_1 sont répartis en 4 classes (cf 1.5.3), les points normaux, les points inusuels, le bruit et les points normaux décalés sur les spectrogrammes. Seuls les points inusuels sont à détecter.

Calibration des paramètres des tests d'hypothèses

Le seul paramètre devant être calibré pour cette approche est le seuil de détection. Pour le définir nous représentons le taux de détection des différentes classes de points de la base de validation Ω_{Val} en fonction de différents seuils sur les p-valeurs (Figure 4.7). Pour le dictionnaire basé sur les curvelets, nous disposons de deux niveaux de détection le premier au niveau des résidus positifs et le second au niveau des résidus négatifs. Cela permettait de laisser une certaine marge au niveau du choix du seuil. Cependant, cette double validation n'est pas présente pour ce dictionnaire adapté aux données, le seuil doit donc être sélectionné de manière à détecter l'ensemble des points inusuels tout en évitant la détection à tort des points normaux. Le seuil sélectionné est donc moins conservateur que celui défini pour les curvelets.

Nous observons un fort taux de bonnes détections des points inusuels pour des niveaux de seuil faibles, ainsi qu'un fort taux de fausses détections des points décalés (Figure 4.7). Cela signifie que les raies décalées (donc les raies liées au N_1) sont mal représentées par le dictionnaire entraînant des résidus de fortes intensités au niveau de ces raies. Ces raies possèdent des intensités vibratoires plus importantes que les raies inusuelles entraînant donc une détection équivalente entre les points atypiques et les points normaux décalés. De plus, le taux de détection des autres points normaux augmente rapidement avec le seuil (beaucoup plus que pour le dictionnaire

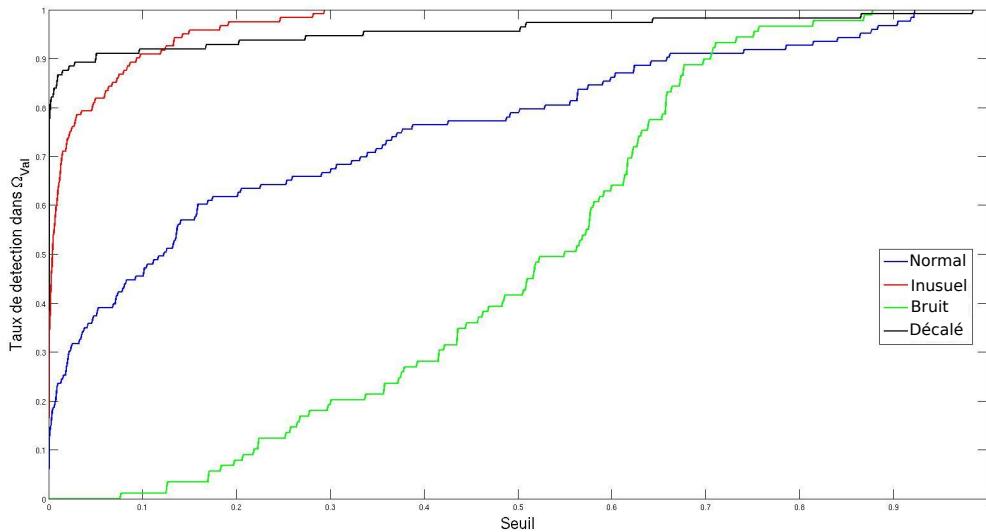


FIGURE 4.7 – Taux de détection pour les différentes classes de points de la base de validation Ω_{Val} en fonction du seuil sur les p-valeurs. Les points atypiques (rouge) et les points se trouvant sur des raies normales décalées (noir) sont fortement détectés pour des petites valeurs de seuils. Les points normaux (bleu) et du bruit (vert) sont faiblement détectés mais augmentent rapidement en fonction du seuil de détection. Nous fixons donc un niveau de seuils bas.

des curvelets), pour un seuil de 0.1, il atteint les 40%. Nous avons donc choisi comme seuil de détection sur les p-valeurs :

$$s = 0.03.$$

Ce seuil permet un taux de bonne détection d'environ 80% et un taux de détection des points normaux d'environ 25% et de 90% des points décalés dans la base de validation. La figure 4.8 présente des images de détection de différents patchs contenant des signatures inusuelles pour différentes valeurs de seuil. Lorsque le seuil de détection est trop faible, le modèle est trop strict et les signatures atypiques ne sont pas détectées. En cas de seuil trop important de nombreux points normaux sont détectés à tort. Le seuil choisi permet de faire un compromis entre ces 2 effets, il est reporté sur les autres patchs.

Calibration des paramètres pour les valeurs extrêmes

Pour ce système de détection, le paramètre impactant le seuil de détection est le nombre de points utilisés pour calibrer la distribution des valeurs extrêmes. Nous représentons le taux de détection des différentes classes de points de la base de validation en fonction de la taille des résidus positifs dont est issue la distribution des extrêmes (Figure 4.9). Le taux de bonnes détections augmente avec le nombre de résidus pris en compte car le seuil devient de plus en plus faible. Cependant le taux de fausses détections augmente également en fonction du nombre de données. Nous sélectionnons comme nombre de données pour estimer la distribution des

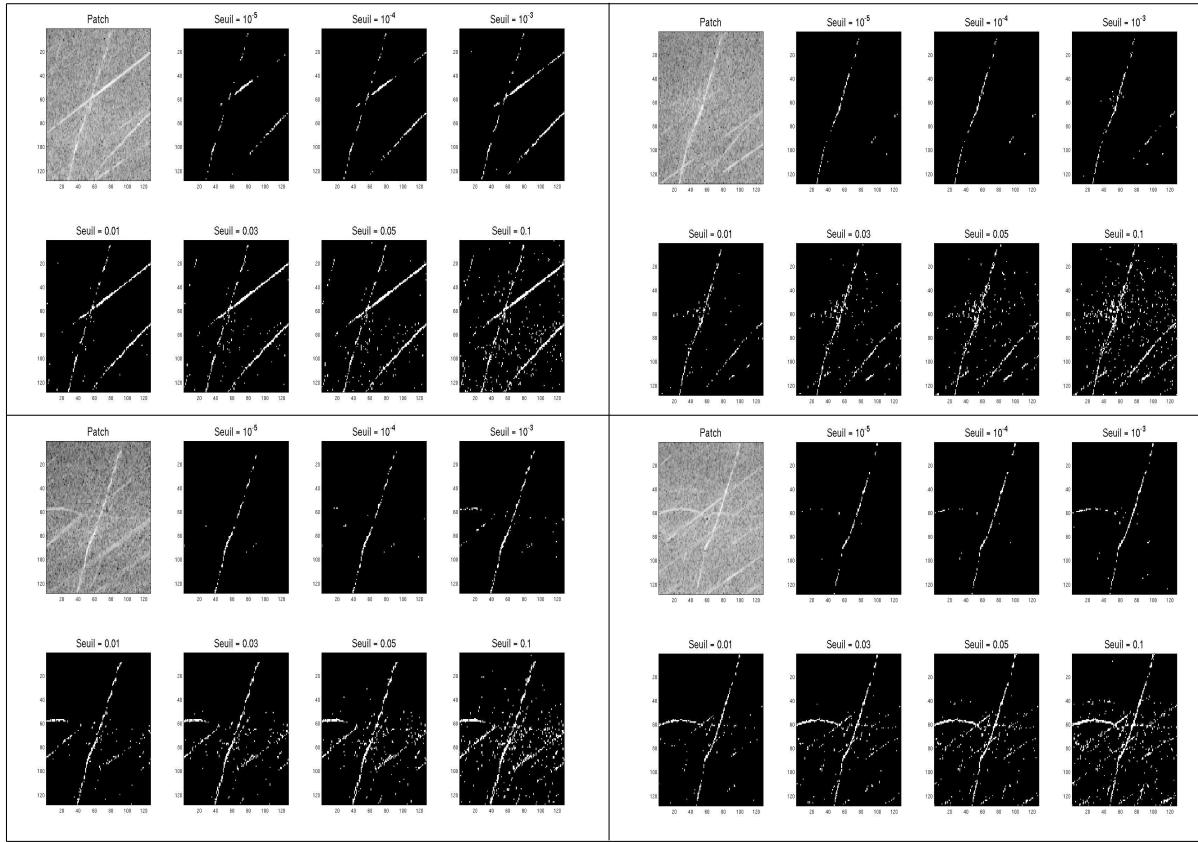


FIGURE 4.8 – Points détectés pour différents patchs de la base de validation à partir d'un seuil sur les p-valeurs des résidus issus du dictionnaire de la NMF pour différentes valeurs de seuil. Pour des seuils trop faibles, les signatures atypiques ne sont pas détectables, tandis que des seuils trop importants entraînent la détection des signatures normales.

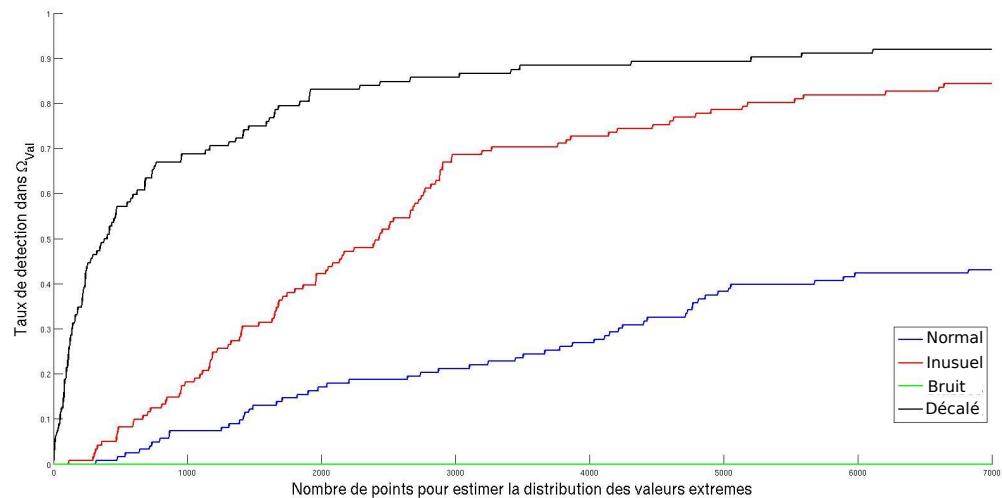


FIGURE 4.9 – Taux de détection pour les différentes classes de points de la base de validation Ω_{Val} en fonction du nombre de résidus utilisés pour calibrer la distribution des valeurs extrêmes. Les détections des points atypiques (rouge) et des points se situant sur des raies normales décalées (noir) augmentent fortement en fonction du nombre de points pris en compte pour l'estimation de la distribution des valeurs extrêmes. Le taux de détection des points normaux (bleu) augmente beaucoup plus faiblement. Le nombre de points pris en compte pour l'estimation de la distribution doit donc être important.

extrêmes :

$$n_{max} = 5178.$$

Cette valeur permet un taux de bonnes détections de 80%, tout en limitant le taux de fausses détections des points normaux de la base de validation de \mathcal{B}_1 . Le taux de détection des points décalés reste supérieur. Par manque de points annotés dans les autres patchs, cette valeur est reportée sur les autres.

4.5.4 Résultats sur la base de test Ω_{Test}

Résultats sur la base de test annotée ponctuellement

Le tableau 4.2 donne les taux de détection des différentes classes de points annotés de la base de test Ω_{Test} de \mathcal{B}_1 obtenus à partir de différentes méthodes de définition de seuil sur les résidus de reconstruction issus du dictionnaire de normalité de la NMF appris sur différentes données d'apprentissage.

TABLE 4.2 – Taux de détection des différentes classes de points de la base de test Ω_{Test} à partir du modèle défini par la NMF avec les scores définis par les p-valeurs et les valeurs extrêmes des résidus pour différentes données d'apprentissage

Classe de points	P-valeurs sur les résidus	Valeurs extrêmes sur les résidus
Classe "normal"	$30.8\% \pm 3.6\%$	$35.8\% \pm 3.2\%$
Classe "inusuel"	$79.7\% \pm 1.2\%$	$83.1\% \pm 1.2\%$
Classe "bruit"	0%	0%
Classe "décalé"	$87.8\% \pm 4.4\%$	$88.5\% \pm 3.3\%$

Cette approche donne de bons résultats de détection pour les points atypiques mais détectent aussi les points décalés, les raies N_1 sont donc fortement détectées par cette méthode. Les résultats des deux méthodes de définition de seuil sont très proches. La détection des autres points normaux provient principalement de points isolés ou des points situés sur des raies normales de fortes intensités. Afin de limiter cet effet, nous pouvons appliquer un filtre médian sur les détections pour supprimer les points dont aucun voisin ne fait partie des points détectés.

Résultats sur l'ensemble des patchs

Le tableau 4.4 présente des résultats sur l'ensemble des patchs de la base de test en considérant un critère d'erreur identique à celui défini pour les curvelets (3.15). Nous calculons la proportion de points détectés faisant partie d'une zone atypique pour les patchs contenant des signatures inusuelles et le taux de points détectés pour les patchs ne contenant pas de signatures inusuelles. Un point classifié comme inusuel par notre modèle est considéré comme une bonne détection s'il se trouve dans une des zones atypiques extraites de notre base de données. Nous mettons NA pour les patchs dans lesquels aucun moteur de la base de test ne possède de signature inusuelle.

Le tableau 4.4 est divisé en plusieurs sous-tableaux, chacun d'entre eux correspondant à un des patchs. Le contenu de ces sous-tableaux est donné dans le tableau 4.3.

TABLE 4.3 – Structure des sous-tableaux de résultats pour le modèle défini par le dictionnaire de la NMF

Taux de bonnes détection à partir de l'approche des p-valeurs pour les patchs contenant des signatures inusuelles	Taux de points détectés à partir de l'approche des p-valeurs pour les patchs sans signatures inusuelles
Taux de bonnes détection à partir de l'approche des valeurs extrêmes pour les patchs contenant des signatures inusuelles	Taux de points détectés à partir de l'approche des valeurs extrêmes pour les patchs sans signatures inusuelles

Ce tableau permet de voir un bon pourcentage de points détectés pour plusieurs patchs contenant des signatures inusuelles. Certains patchs possèdent cependant un faible taux de détection, il peut s'agir de patchs dont les points considérés comme inusuels constituent les points normaux ajoutés lors de l'extraction ou des points inusuels. De plus, il est à remarquer que ces approches rejettent un certain pourcentage de points normaux dû au seuil fixé intra-patch que ce soit pour les p-valeurs ou les valeurs extrêmes et imposent donc nécessairement des points à classifier comme inusuels sur tous les patchs. Ce pourcentage de détection reste néanmoins faible comparativement à la taille du patch. Ces résultats sont à relativiser car les points détectés dans les zones atypiques peuvent correspondre à des points normaux situés dans ces cadres lors de l'extraction.

4.5.5 Complémentarité des approches adaptatives et non-adaptatives

Les modèles définis à partir des dictionnaires issus de la NMF et des curvelets permettent tous deux la détection des signatures atypiques présentes sur les patchs. Le dictionnaire des curvelets fonctionnent de manière locale sur les patchs tandis que celui de NMF gère les patchs dans leur globalité. Cela est visible à travers les atomes des dictionnaires qui correspondent à des parties de raies pour les curvelets et à des raies entières pour la NMF. Les deux modèles entraînent également la détection de plusieurs points normaux sur les patchs. Le dictionnaire \mathcal{D}^{NMF} permet la reconstruction des raies au sein d'un patch mais ne donne pas une estimation correcte des intensités vibratoires les plus fortes. Les atomes du dictionnaire caractérisent l'intégralité du patch et non pas une partie seulement. Etant donné que seules les opérations additives sont appliquées, caractériser correctement une raie vibratoire de forte intensité impliquerait une augmentation des coefficients associés aux atomes. Cette augmentation n'impactera pas uniquement la raie vibratoire mais tout l'atome et donc a fortiori l'intégralité du patch augmentant ainsi l'erreur de reconstruction globale. Ainsi, le dictionnaire de la NMF permet la reconstruction de la structure du patch mais pas des intensités, entraînant des détections sur les raies normales de fortes intensités. A l'inverse, les curvelets permettent une bonne reconstruction des intensités vibratoires et de la structure du patch, malgré des raies vibratoires reconstruites de manière plus grossière. Chaque atome du dictionnaire correspond à une sous-zone du patch et donc l'augmentation des coefficients n'impacte pas l'intégralité du patch. Cependant le dictionnaire des curvelets entraîne

TABLE 4.4 – Taux de détection sur l'ensemble des patchs de la base de test à partir du modèle de normalité défini à partir de la NMF

<i>NA</i>	$3.55\% \pm 0.03\%$	<i>NA</i>	$3.93\% \pm 0.03\%$	$1.8\% \pm 0.3\%$	$3.49\% \pm 0.04\%$
<i>NA</i>	$5.10\% \pm 0.13\%$	<i>NA</i>	$5.32\% \pm 0.05\%$	$1.4\% \pm 0.3\%$	$4.85\% \pm 0.05\%$
<i>NA</i>	$4.02\% \pm 0.03\%$	<i>NA</i>	$4.25\% \pm 0.04\%$	$70.8\% \pm 0.6\%$	$4.16\% \pm 0.02\%$
<i>NA</i>	$5.62\% \pm 0.06\%$	<i>NA</i>	$5.73\% \pm 0.04\%$	$69.5\% \pm 0.7\%$	$5.67\% \pm 0.02\%$
$25.5\% \pm 0.4\%$	$4.27\% \pm 0.01\%$	$3.5\% \pm 0.6\%$	$4.1\% \pm 0.01\%$	$64.5\% \pm 2.1\%$	$3.46\% \pm 0.02\%$
$25.7\% \pm 0.5\%$	$6.14\% \pm 0.06\%$	$4.3\% \pm 0.5\%$	$5.43\% \pm 0.01\%$	$63.1\% \pm 1.6\%$	$4.5\% \pm 0.01\%$
$68.5\% \pm 0.6\%$	$4.1\% \pm 0.01\%$	$41.6\% \pm 0.3\%$	$3.44\% \pm 0.01\%$	$52.1\% \pm 0.5\%$	$4.28\% \pm 0.01\%$
$65.8\% \pm 0.4\%$	$5.62\% \pm 0.01\%$	$41.7\% \pm 0.3\%$	$4.3\% \pm 0.03\%$	$51.2\% \pm 0.1\%$	$5.97\% \pm 0.05\%$
$31.9\% \pm 0.3\%$	$4.40\% \pm 0.03\%$	$29.8\% \pm 0.3\%$	$3.19\% \pm 0.03\%$	$34.1\% \pm 0.4\%$	$3.66\% \pm 0.03\%$
$31.1\% \pm 0.2\%$	$6.12\% \pm 0.03\%$	$30.3\% \pm 0.3\%$	$4.06 \pm 0.06\%$	$34.3\% \pm 0.3\%$	$4.49\% \pm 0.05\%$
$55.7\% \pm 0.5\%$	$4.68\% \pm 0.02\%$	$54.4\% \pm 0.2\%$	$4.38\% \pm 0.01\%$	$82.2\% \pm 0.2\%$	$2.17\% \pm 0.02\%$
$56.0\% \pm 0.4\%$	$6.63\% \pm 0.02\%$	$53.3\% \pm 0.2\%$	$6.31\% \pm 0.03\%$	$82.1\% \pm 0.1\%$	$2.40\% \pm 0.02\%$
$51.1\% \pm 0.3\%$	$4.61\% \pm 0.02\%$	$50.5\% \pm 0.4\%$	$4.41\% \pm 0.01\%$	$55.8\% \pm 0.3\%$	$2.10\% \pm 0.01\%$
$52.6\% \pm 0.4\%$	$6.74\% \pm 0.06\%$	$49.6\% \pm 0.4\%$	$6.38\% \pm 0.01\%$	$55.5\% \pm 0.5\%$	$2.49\% \pm 0.01\%$
$18.5\% \pm 0.6\%$	$4.41\% \pm 0.01\%$	$35.0\% \pm 0.3\%$	$4.02\% \pm 0.01\%$	$47.9\% \pm 0.3\%$	$4.36\% \pm 0.02\%$
$19.0\% \pm 0.5\%$	$6.27\% \pm 0.03\%$	$35.1\% \pm 0.2\%$	$5.27\% \pm 0.03\%$	$49.4\% \pm 0.2\%$	$6.29\% \pm 0.02\%$
$7.9\% \pm 0.9\%$	$4.61\% \pm 0.02\%$	$23.6\% \pm 0.9\%$	$4.12\% \pm 0.03\%$	$37.3\% \pm 0.5\%$	$4.35\% \pm 0.02\%$
$7.13\% \pm 0.5\%$	$6.65\% \pm 0.03\%$	$23.5\% \pm 0.7\%$	$5.77\% \pm 0.03\%$	$38.0\% \pm 0.6\%$	$6.37\% \pm 0.01\%$
<i>NA</i>	$4.73\% \pm 0.02\%$	<i>NA</i>	$4.24\% \pm 0.01\%$	$17.9\% \pm 0.7\%$	$4.20\% \pm 0.03\%$
<i>NA</i>	$6.64\% \pm 0.01\%$	<i>NA</i>	$6.10\% \pm 0.05\%$	$19.8\% \pm 0.4\%$	$5.73\% \pm 0.04\%$
$25.8\% \pm 0.8\%$	$4.53\% \pm 0.02\%$	<i>NA</i>	$4.35\% \pm 0.03\%$	$21.9\% \pm 0.6\%$	$3.87\% \pm 0.01\%$
$21.7\% \pm 0.8\%$	$6.70\% \pm 0.05\%$	<i>NA</i>	$6.14\% \pm 0.02\%$	$21.0\% \pm 0.8\%$	$4.89\% \pm 0.03\%$
$7.0\% \pm 0.3\%$	$4.26\% \pm 0.01\%$	$14.1\% \pm 1.4\%$	$3.26\% \pm 0.02\%$	$5.5\% \pm 0.2\%$	$2.99\% \pm 0.01\%$
$7.8\% \pm 0.4\%$	$6.31\% \pm 0.05\%$	$13.8\% \pm 1.2\%$	$4.03\% \pm 0.06\%$	$5.5\% \pm 0\%$	$3.52\% \pm 0.03\%$
$7.2\% \pm 0.2\%$	$4.51\% \pm 0.02\%$	$18.7\% \pm 0.3\%$	$2.75\% \pm 0.01\%$	$12.3\% \pm 0.4\%$	$1.89\% \pm 0.01\%$
$8.1\% \pm 0.6\%$	$6.97\% \pm 0.05\%$	$18.9\% \pm 0.2\%$	$3.37\% \pm 0.03\%$	$13.3\% \pm 0.2\%$	$2.22\% \pm 0.01\%$
<i>NA</i>	$4.54\% \pm 0.01\%$	$3.6\% \pm 0.3\%$	$3.01\% \pm 0.01\%$	$48.8\% \pm 0.9\%$	$3.31\% \pm 0.03\%$
<i>NA</i>	$7.20\% \pm 0.01\%$	$3.8\% \pm 0.1\%$	$3.57\% \pm 0.05\%$	$48.7\% \pm 0.7\%$	$4.16\% \pm 0.05\%$
<i>NA</i>	$4.18\% \pm 0.02\%$	$60.5\% \pm 0.3\%$	$2.07\% \pm 0.02\%$	$51.9\% \pm 0.1\%$	$4.14\% \pm 0.03\%$
<i>NA</i>	$6.40\% \pm 0.03\%$	$59.7\% \pm 0.3\%$	$2.28\% \pm 0.04\%$	$50.9\% \pm 0.2\%$	$5.61\% \pm 0.01\%$
$14.8\% \pm 4\%$	$4.47\% \pm 0.01\%$	$45.0\% \pm 0.7\%$	$2.16\% \pm 0.02\%$	$42.0\% \pm 0.3\%$	$3.66\% \pm 0.01\%$
$16.0\% \pm 0.2\%$	$6.80\% \pm 0.02\%$	$44.0\% \pm 0.5\%$	$2.56\% \pm 0.05\%$	$41.0\% \pm 0.4\%$	$4.50\% \pm 0.01\%$
$92.7\% \pm 1.3\%$	$3.89\% \pm 0.03\%$	$45.9\% \pm 0.8\%$	$2.36\% \pm 0.01\%$	$16.7\% \pm 0.1\%$	$3.35\% \pm 0.02\%$
$91.5\% \pm 1.4\%$	$6.08\% \pm 0.12\%$	$45.3\% \pm 1.1\%$	$3.01\% \pm 0.04\%$	$16.3\% \pm 0\%$	$4.05\% \pm 0.02\%$
$30.0\% \pm 3.2\%$	$3.21\% \pm 0.04\%$	$6.3\% \pm 1.1\%$	$3.05\% \pm 0.02\%$	$22.4\% \pm 0.1\%$	$3.28\% \pm 0.01\%$
$31.6\% \pm 1.8\%$	$4.83\% \pm 0.11\%$	$6.1\% \pm 0.8\%$	$4.29\% \pm 0.02\%$	$21.6\% \pm 0.1\%$	$3.90\% \pm 0.02\%$

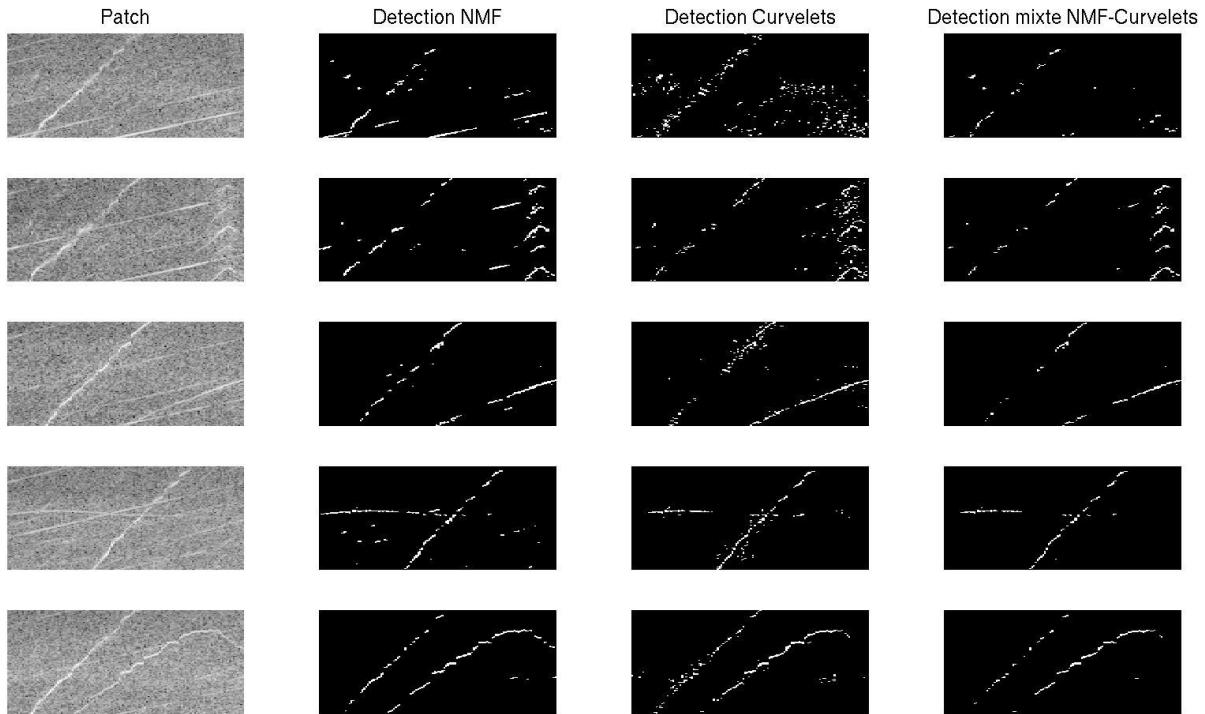


FIGURE 4.10 – Détection des points inusuels à partir des modèles de normalité définis par la NMF, les curvelets et l’approche mixte combinant les 2 dictionnaires.

la détection de plusieurs points autour des signatures atypiques et des raies liées au N_1 . Ainsi les deux dictionnaires permettent la détection des signatures inusuelles mais n’entraînent pas les mêmes fausses détections. Il est donc intéressant de les combiner sous la forme d’un vote pour les limiter. Un point est considéré comme inusuel dans cette approche mixte lorsque les 2 modèles le considèrent comme inusuel.

$$\hat{Y}_{f,N_2}^i = \min(\hat{Y}_{f,N_2}^{i,\mathcal{C}}, \hat{Y}_{f,N_2}^{i,NMF}) \quad \forall(f, N_2)$$

La figure 4.10 présente la détection des points atypiques sur 5 patchs (définis dans la figure 2.3, un patch normal (1ère ligne) et 4 patchs contenant différentes signatures inusuelles) à partir des modèles de normalité définis à partir de la NMF combiné à un filtrage de voisinage, des curvelets et du classifieur combinant ces deux dictionnaires par un système de vote. Les deux dictionnaires permettent la détection des points atypiques, nous pouvons remarquer qu’en mélangeant les deux approches nous réduisons les points détectés à tort et conservons une bonne détection des signatures inusuelles. La combinaison des dictionnaires est donc efficace pour la détection d’anomalies sur les spectrogrammes.

4.6 Conclusions

Le dictionnaire adaptatif

Le dictionnaire adaptatif issu de la NMF permet une bonne caractérisation du modèle de normalité des patchs. Un dictionnaire est appris pour chaque patch séparément et uniquement sur ceux ne présentant aucune signature inusuelle. A partir de ce dictionnaire, les patchs reconstruits constituent une estimation normale de ces derniers. Ils ne présentent plus usuellement de signatures atypiques étayant l'hypothèse d'une bonne caractérisation de la normalité à partir du dictionnaire adaptatif en dimension réduite.

L'étude du patch dans sa globalité ne permet pas la détection des patchs inusuels. Les coefficients de représentation sont en dimension réduite par rapport à la dimension des patchs et n'ont pas la possibilité d'être affecté par les anomalies. Ils permettent uniquement la caractérisation des signatures redondantes au sein du patch. L'erreur de reconstruction globale dilue l'impact issu des signatures atypiques par rapport à l'ensemble des résidus issus des éléments normaux sur le patch. Cette mesure permet la détection des patchs anormaux lorsque les signatures sont de fortes intensités et en grand nombre, c'est-à-dire lors d'un réel endommagement sur le moteur.

La considération des résidus ponctuels de reconstruction permet de considérer les erreurs au niveau de chaque point et donc de détecter ceux dont le modèle de normalité ne donne pas une bonne caractérisation. Cela permet de détecter finement les signatures inusuelles au sein du patch. Cependant, la détection est effectuée à partir des seuils fixés sur les résidus intra-patch, le seuil est fixé sur la distribution des résidus ou à partir de la distribution des valeurs extrêmes. Cela entraîne une détection systémataque des points extrêmes des résidus y compris sur les patchs ne contenant pas de signatures inusuelles.

Les approches de représentation de la normalité par des dictionnaires

Les approches par dictionnaire ont permis de caractériser la normalité permettant une détection fine des signatures inusuelles à partir de la reconstruction normale des patchs. Les dictionnaires non-adaptatifs permettent de considérer des dictionnaires surcomplets malgré un faible nombre de données par rapport à la taille des patchs. Les atomes du dictionnaire sont prédéfinis et consistent en de petites parties de raies permettant de caractériser les patchs localement. Chaque atome du dictionnaire caractérise donc une zone du patch. Les dictionnaires data-driven sont en dimension réduite pour éviter le sur-apprentissage, les différents atomes caractérisent différentes structures de l'intégralité du patch et permettent une reconstruction des patchs sans aucune signature atypique. Ce type de dictionnaire est donc idéal pour définir le modèle de normalité. La détection des signatures inusuelles s'effectue point par point sur chaque patch en fixant un seuil spécifique aux données sur les résidus de reconstruction des patchs à partir du modèle de normalité. Dans le cas du dictionnaire non-adaptatif, le dictionnaire engendre des

artéfacts autour des signatures inusuelles permettant de les utiliser comme un filtre sur les résidus positifs caractérisant les points inusuels. Dans le cas des dictionnaires adaptatifs, seuls les résidus positifs permettent de détecter les points inusuels. La combinaison des deux dictionnaires apporte une détection plus fine des points atypiques et permet d'effectuer une double vérification sur les dictionnaires afin de limiter les mauvaises détections.

La détection fine des signatures inusuelles s'effectue à partir des résidus intra-patchs et entraîne la détection de points sur tous les patchs contenant ou ne contenant pas de signatures atypiques. Cette détection est effectuée sans tenir compte des autres données associées au même patch. Le seuil de détection est fixé à partir des résidus du patch et est identique pour tous les points présents sur le patch. Cependant, un point de forte intensité peut être mal caractérisé par le dictionnaire du patch et entraîné de forts résidus de représentation. Cependant bien que l'intensité de ce point peut être considérée comme importante par rapport au patch étudié, elle peut ne pas être inusuelle par rapport aux points identiques sur les données normales. Ce point n'est donc une anomalie mais est considéré comme tel par l'algorithme de détection basé sur les dictionnaires comme ce point est vu comme un extrême de la distribution des résidus. Il semble donc pertinent de considérer un modèle de normalité au niveau de chaque point des différents patchs. Cela permettrait de tenir compte de la variabilité des mêmes points sur les différentes données afin de détecter uniquement les points dont l'intensité vibratoire ne correspond pas à la distribution des points normaux aux mêmes coordonnées.

Les approches par dictionnaire permettent donc une bonne détection des signatures atypiques sur les différents patchs du spectrogramme sans a priori sur la forme ou position de ces signatures inusuelles.