

FIGURE 6.2 – Structure du voisinage direct (bleu) d'ordre 1 pour le point étudié (rouge)

6.3.2 Le modèle de normalité

Le modèle provient de l'estimation de la densité conditionnelle du point étudié sachant les intensités vibratoires de ses voisins directs. Cette distribution est estimée uniquement sur les spectrogrammes dont le patch est considéré comme normal afin que tous les points considérés dans la mise en place du modèle soient normaux. Les points atypiques ne sont pas isolés sur les spectrogrammes, ils font partie d'une structure sous forme de raies. Autour d'un point inusuel étudié se trouvent plusieurs points inusuels. Ces points ne sont pas utilisés lors de l'estimation de la densité entraînant des densités jointes très faibles se situant dans les extrêmes de la distribution. La densité jointe des variables explicatives et de la variable étudié est bien plus faible que la densité jointe des variables explicatives uniquement pour un point atypique alors que ces deux densités jointes seront du même ordre de grandeur pour un point normal.

Le modèle de normalité est donc défini par rapport à la densité conditionnelle en tout point (f, N_2) du patch par rapport au voisinage \mathcal{V}_{f, N_2} du point estimée à partir de l'ensemble des points normaux $S_{f, N_2}^{\Omega_{App}} = \{S_{f, N_2}^i\}_{i \in \Omega_{App}^{f, N_2}}$ et de leur voisinage associé $\mathcal{V}_{f, N_2}^{\Omega_{App}} = \{\mathcal{V}_{f, N_2}^i\}_{i \in \Omega_{App}}$ (6.5).

$$\forall (f, N_2) \quad \hat{f}_{(f, N_2)} | \mathcal{V}_{f, N_2} \left(x | \Omega_{App}^{f, N_2}, H_{SV}, H_V, \mathcal{V}_{f, N_2} \right) = \frac{\sum_{i \in \Omega_{App}^{f, N_2}} K_{H_{SV}}(x - S_{f, N_2}^i, \mathcal{V}_{f, N_2}^x - \mathcal{V}_{f, N_2}^i)}{\sum_{i \in \Omega_{App}^{f, N_2}} K_{H_V}(\mathcal{V}_{f, N_2}^x - \mathcal{V}_{f, N_2}^i)} \quad (6.5)$$

\mathcal{V}_{f, N_2}^x correspond au voisinage du point x étudié, par abus de langage et pour simplifier les notations, nous considérons également \mathcal{V}_{f, N_2}^x comme les intensités vibratoires des voisins. H_{SV} et H_V correspondent respectivement aux matrices d'échelle du noyau utilisé pour estimer la loi jointe du point étudié avec son voisinage et la loi jointe du voisinage. La seconde matrice peut être extraite de la première ou peut être estimée. Le noyau gaussien a été choisi pour estimer la densité conditionnelle pour accélérer les calculs malgré le biais à l'origine.

Dans cette section, nous considérons deux matrices d'échelle H , la première diagonale permettant une simplification des calculs et la seconde pleine permettant de donner une orientation spécifique au noyau. Cette seconde approche est intéressante car un point se trouvant sur une raie attendue devrait avoir son noyau associé avec une orientation similaire à cette raie. Cependant cette approche complexifie le calcul empêchant toute simplification et impose certaines approximations. Dans la suite nous donnons les résultats pour ces deux types de matrices d'échelle.

La matrice d'échelle doit être estimée pour chaque point du spectrogramme entraînant un grand nombre d'estimations. Les différentes méthodes avancées proposées nécessitent une optimisation pour trouver la matrice H optimale. Ces méthodes sont difficilement applicables pour tous les points. Nous avons donc opté pour la méthode du pouce défini en (6.2) afin de donner une estimation rapide et efficace des matrices d'échelle pour chaque point du spectrogramme.

6.3.3 Le score de détection

Le score de détection des points inusuels s'effectue à partir d'un test statistique opposant l'hypothèse \mathcal{H}_0^{f,N_2} : le point aux coordonnées (f, N_2) est normal sachant son voisinage d'ordre 1 contre l'hypothèse \mathcal{H}_1^{f,N_2} : le point aux coordonnées (f, N_2) est atypique sachant son voisinage d'ordre 1. La distribution sous \mathcal{H}_0^{f,N_2} est approximée par la loi de normalité estimée, ce test revient à un test d'adéquation des données à cette distribution. Ce test est appliqué pour chaque point des spectrogrammes. La décision est alors effectuée sur les p-valeurs (6.6) associées à ces tests.

$$pval_{f,N_2}^{i,K_{\mathcal{V}}} = \mathbb{P}_{\mathcal{H}_0^{f,N_2}} (X > S_{f,N_2}^i | \mathcal{V}_{f,N_2}^i) \approx \mathbb{P}_{\hat{f}_{(f,N_2)}|\mathcal{V}_{f,N_2}} (X > S_{f,N_2}^i | \mathcal{V}_{f,N_2}) \quad (6.6)$$

Le calcul de cette p-valeur est différent suivant la matrice d'échelle H diagonale ou pleine.

Matrice H diagonale

Dans ce cas, le noyau peut s'écrire sous sa forme multiplicative :

$$K_H(x) = \prod_{i=1}^d K_{H_i}(x^i) = \prod_{i=1}^d \frac{1}{H_i} K_{\mathcal{N}}\left(\frac{x^i}{H_i}\right),$$

avec H_i l'élément diagonal i de la matrice d'échelle H et x^i la i ème composante de x .

Le calcul de la p-valeur correspond alors à :

$$\begin{aligned}
pval_{f,N_2}^{i,K_V} &= \int_{S_{f,N_2}^i}^{+\infty} \hat{f}_{(f,N_2)} | \mathcal{V}_{f,N_2} (x | \Omega_{App}^{f,N_2}, H_{SV}, H_V, \mathcal{V}_{f,N_2}) dx \\
&= \int_{S_{f,N_2}^i}^{+\infty} \frac{\sum_{j \in \Omega_{App}^{f,N_2}} K_{H_{SV}}(x - S_{f,N_2}^j, \mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j)}{\sum_{j \in \Omega_{App}^{f,N_2}} K_{H_V}(\mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j)} dx \\
&= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \int_{S_{f,N_2}^i}^{+\infty} K_{H_{SV}}(x - S_{f,N_2}^j, \mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j) dx \\
&= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \int_{S_{f,N_2}^i}^{+\infty} \frac{1}{H_{d+1}} K_N \left(\frac{x - S_{f,N_2}^j}{H_{d+1}} \right) \prod_{k=1}^d \frac{1}{H_k} K_N \left(\frac{\mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j}{H_k} \right) dx \\
&= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \underbrace{\prod_{k=1}^d \frac{1}{H_k} K_N \left(\frac{\mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j}{H_k} \right)}_{\mathcal{N}_{\mathcal{V}_{f,N_2}^j, \bar{H}_{SV} \bar{H}_{SV}^T} (\mathcal{V}_{f,N_2}^x)} \underbrace{\int_{S_{f,N_2}^i}^{+\infty} \frac{1}{H_{d+1}} K_N \left(\frac{x - S_{f,N_2}^j}{H_{d+1}} \right) dx}_{\mathcal{N}_{S_{f,N_2}^j, H_{d+1}^2} (x)} \\
&= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \mathcal{N}_{\mathcal{V}_{f,N_2}^j, \bar{H}_{SV} \bar{H}_{SV}^T} (\mathcal{V}_{f,N_2}^x) \times \mathbb{P}_{\mathcal{N}_{S_{f,N_2}^j, H_{d+1}^2}} (X > S_{f,N_2}^i)
\end{aligned}$$

avec \bar{H}_{SV} la matrice extraite de H_{SV} correspondant aux points du voisinage de dimension $d \times d$, $\mathcal{N}_{\mathcal{V}_{f,N_2}^j, \bar{H}_{SV} \bar{H}_{SV}^T}$ la densité de la gaussienne de moyenne \mathcal{V}_{f,N_2}^j et de matrice de covariance $\bar{H}_{SV} \bar{H}_{SV}^T$, H_k le k ème élément diagonal de la matrice H_{SV} et

$$M_V = \sum_{j \in \Omega_{App}^{f,N_2}} K_{H_V} \left(\mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j \right) = \sum_{j \in \Omega_{App}^{f,N_2}} \mathcal{N}_{\mathcal{V}_{f,N_2}^j, H_V H_V^T} (\mathcal{V}_{f,N_2}^x).$$

Donc

$$pval_{f,N_2}^{i,K_V} = \sum_{j \in \Omega_{App}^{f,N_2}} w_j \times \mathbb{P}_{\mathcal{N}_{S_{f,N_2}^j, H_{d+1}^2}} (X > S_{f,N_2}^i) = \sum_{j \in \Omega_{App}^{f,N_2}} w_j \times \left(1 - F_{\mathcal{N}_{S_{f,N_2}^j, H_{d+1}^2}} (S_{f,N_2}^i) \right) \quad (6.7)$$

avec

$$w_j = \frac{\mathcal{N}_{\mathcal{V}_{f,N_2}^j, \bar{H}_{SV} \bar{H}_{SV}^T} (\mathcal{V}_{f,N_2}^x)}{\sum_{j \in \Omega_{App}^{f,N_2}} \mathcal{N}_{\mathcal{V}_{f,N_2}^j, H_V H_V^T} (\mathcal{V}_{f,N_2}^x)}$$

Par abus de langage, nous notons la densité de la loi $\mathcal{N}_{\mu, \sigma^2}$ par ce terme également.

La p-valeur dans le cas d'une matrice d'échelle diagonale correspond donc à la moyenne du complémentaire de la fonction de répartition des lois normales $\left\{ \mathcal{N}_{S_{f,N_2}^j, H_{d+1}^2} \right\}_{j \in \Omega_{App}^{f,N_2}}$ au point S_{f,N_2}^i pondérée par le ratio entre le noyau appliqué au voisinage d'une des observations et la somme des noyaux appliqués aux voisinages de toutes les observations. Les w_j peuvent ne pas sommer à 1 du fait de la différence entre les matrices d'échelle estimées en $d+1$ et d dimensions. Cependant cet écart n'est pas significatif. La pondération permet de donner plus de poids aux

données d'apprentissage dont les voisins sont proches des voisins des données étudiées.

En divisant par la densité jointe des points voisins, il est possible que ce dénominateur soit numériquement nul entraînant une division par 0. Ce phénomène se limite à une faible nombre de points. Le voisinage direct du point étudié contient donc des points fortement éloignés de la normalité, nous avons alors choisi de déclarer ces points comme inusuels.

Matrice H pleine

Dans ce cas de figure, il n'existe pas de simplification de la formulation de la densité conditionnelle. De plus le calcul de la p-valeur n'est pas simplifiée par l'utilisation du noyau gaussien étant donné que nous cherchons à estimer la fonction de répartition sur une seule des dimensions tout en tenant compte des produits croisés entre les différents directions.

$$\begin{aligned}
 pval_{f,N_2}^{i,K_V} &= \int_{S_{f,N_2}^i}^{+\infty} \hat{f}_{(f,N_2)|\mathcal{V}_{f,N_2}}(x|\Omega_{App}^{f,N_2}, H_{SV}, H_V, \mathcal{V}_{f,N_2}) dx \\
 &= \int_{S_{f,N_2}^i}^{+\infty} \frac{\sum_{j \in \Omega_{App}^{f,N_2}} K_{H_{SV}}(x - S_{f,N_2}^j, \mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j)}{\sum_{j \in \Omega_{App}^{f,N_2}} K_{H_V}(\mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j)} dx \\
 &= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \int_{S_{f,N_2}^i}^{+\infty} K_{H_{SV}}(x - S_{f,N_2}^j, \mathcal{V}_{f,N_2}^x - \mathcal{V}_{f,N_2}^j) dx \\
 &= \frac{1}{M_V} \sum_{j \in \Omega_{App}^{f,N_2}} \underbrace{\int_{S_{f,N_2}^i}^{+\infty} \mathcal{N}\left(\begin{pmatrix} \mathcal{V}_{f,N_2}^j \\ S_{f,N_2}^j \end{pmatrix}, H_{SV} H_{SV}^T\right)(x, \mathcal{V}_{f,N_2}^x) dx}_{(*)}
 \end{aligned}$$

Il s'agit donc de calculer le complémentaire de la fonction de répartition mais uniquement sur une dimension de la densité de la distribution normale. Cette densité n'est pas séparable, il est donc impossible de donner la valeur réelle de cette intégrale. Nous en calculons donc une estimation.

Nous estimons l'intégrale à partir de la méthode des trapèzes utilisée pour estimer les intégrales de Riemann (6.8). Nous discrétisons l'espace d'intensité des points étudiés par la suite $(x_k)_{k \in \mathbb{N}}$ telle que $x_{k+1} = x_k + \xi$, avec $\xi = 10^{-4}$. Cette méthode permet de donner une estimation de l'intégrale qui ne somme pas à 1 sur l'ensemble de l'espace pour la fonction de densité, nous normalisons donc l'estimation de l'intégrale obtenue par M , l'estimation de cette même intégrale sur \mathbb{R}_+ . L'infini considéré dans le calcul de l'intégrale correspond à une valeur suffisamment

grande pour considérer la densité comme nulle.

$$(\star) = \frac{\xi}{2M} \sum_{k|x_k=S_{f,N_2}^i}^{+\infty} \left\{ \mathcal{N}_{\begin{pmatrix} \mathcal{V}_{f,N_2}^j \\ S_{f,N_2}^j \end{pmatrix}, H_{S\nu}H_{S\nu}^T} (x_{k+1}, \mathcal{V}_{f,N_2}^x) + \mathcal{N}_{\begin{pmatrix} \mathcal{V}_{f,N_2}^j \\ S_{f,N_2}^j \end{pmatrix}, H_{S\nu}H_{S\nu}^T} (x_k, \mathcal{V}_{f,N_2}^x) \right\} \quad (6.8)$$

$$M = \frac{\xi}{2} \sum_{k=1}^{+\infty} \left\{ \mathcal{N}_{\begin{pmatrix} \mathcal{V}_{f,N_2}^j \\ S_{f,N_2}^j \end{pmatrix}, H_{S\nu}H_{S\nu}^T} (x_{k+1}, \mathcal{V}_{f,N_2}^x) + \mathcal{N}_{\begin{pmatrix} \mathcal{V}_{f,N_2}^j \\ S_{f,N_2}^j \end{pmatrix}, H_{S\nu}H_{S\nu}^T} (x_k, \mathcal{V}_{f,N_2}^x) \right\}$$

Nous avons donc des formules des p-valeurs pour les modèles de normalité basés sur les distributions conditionnelles dans le cas des matrices d'échelle diagonales et pleines. La détection des points inusuels s'effectue à partir d'un seuil s sur ces p-valeurs.

$$\tilde{Y}_{f,N_2}^{i,K_V} = \mathbb{1} \left\{ pval_{f,N_2}^{i,K_V} \leq s \right\}$$

Le filtrage de voisinage (5.12) reste appliqué sur les détection de manière identique aux approches précédentes.

6.3.4 Calibration du modèle

Convergence des p-valeurs

Nous estimons des densités multidimensionnelles pouvant aller jusqu'à la dimension 9 avec un nombre limité d'observations pour les estimer. Nous vérifions donc la convergence des p-valeurs pour le patch contenant le moins de données normales. La figure 6.3 présente la différence d'estimation entre la p-valeur estimée à partir de $r+1$ données et celle estimée à partir de r données pour 2 points du spectrogramme et différentes données d'apprentissage. La convergence a été étudiée pour les 2 modèles de normalité définis avec différentes structures d'échelle. Nous pouvons voir la différence des estimations entre 2 nombres d'observations successifs diminuer en fonction de ce nombre et converger vers 0. De plus, les estimations restent rapidement dans les mêmes ordres de grandeur permettant une classification des points.

Estimation des seuils de détection

Les seuils de détection sont calibrés sur les données de validation de la base \mathcal{B}_1 annotées ponctuellement. Les taux de détection sont calculés sur les différentes classes de points pour différentes valeurs de seuil. Seuls les points inusuels doivent être détectés. La figure 6.4 présente ces taux de détection pour les modèles de normalité définis respectivement avec une matrice

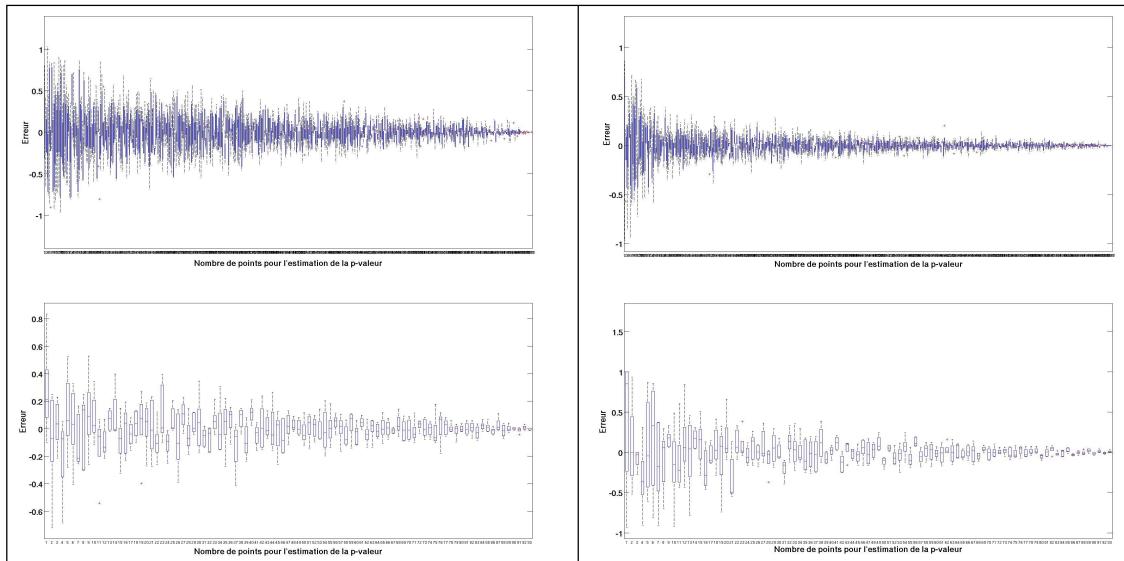


FIGURE 6.3 – Convergence des p-valeurs par rapport au nombre de points utilisés pour estimer la distribution conditionnelle à partir des deux modèles de normalité (matrice d'échelle diagonale (gauche) et pleine (droite)) pour deux points du spectrogramme. Les différentes de p-valeurs diminuent avec le nombre d'observations et convergent vers 0. Elles restent rapidement dans les mêmes ordres de grandeur permettant la classification des patchs.

d'échelle diagonale (à gauche) et une matrice d'échelle pleine (à droite).

Cette approche entraîne une bonne détection des points atypiques mais également la fausse détection des points normaux situés sur des raies se décalant sur les spectrogrammes (les points décalés). Les niveaux de détection sont différents pour les deux approches, l'utilisation d'une matrice d'échelle du noyau diagonale ou pleine modifiant la distribution estimée. Avec un seuil adapté, les méthodes basées sur le modèle de normalité conditionnel permettent toutes les deux de donner un fort niveau de bonnes détections. La figure 6.4 montre également que pour obtenir

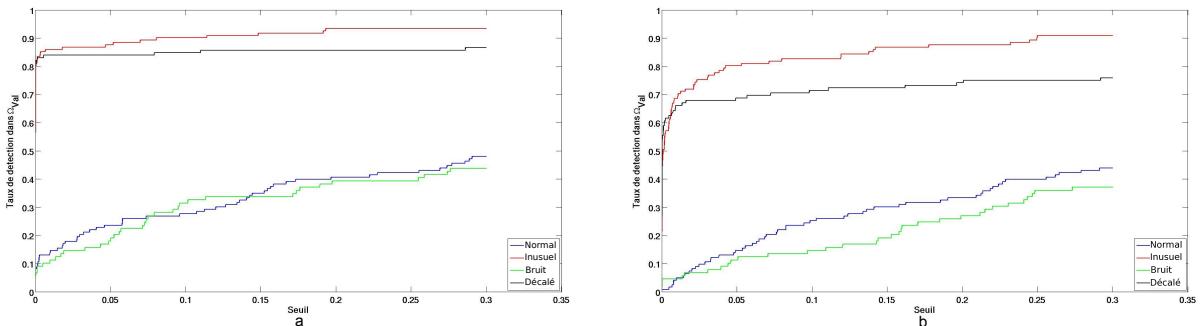


FIGURE 6.4 – Taux de détection des différentes classes de points de la base de validation Ω_{Val} à partir du modèle de normalité défini avec une matrice d'échelle diagonale (a) et une matrice d'échelle pleine (b). Les résultats établis à partir des deux matrices d'échelle sont différents. Les deux modèles permettent la détection des points atypiques (rouge) et des points normaux décalés (noir) pour de petites valeurs de seuil avec de faibles taux de détection des points normaux (bleu) et du bruit (vert). Les seuils de détection optimaux appartiennent donc à cette plage de valeurs et sont différents pour les deux approches.

le même niveau de bonnes détections, le seuil défini pour le modèle de normalité avec une matrice d'échelle diagonale doit être inférieur à celui pour la matrice d'échelle pleine. Nous avons donc défini deux seuils différents, s_{diag} pour le modèle défini avec une matrice diagonale et s_{pleine} pour le modèle avec une matrice pleine.

$$s_{diag} = 10^{-3} \quad s_{pleine} = 0.05$$

Ces seuils entraînent de bons taux de détection à plus de 80% sur la base de validation Ω_{Val} de \mathcal{B}_1 et limitent les fausses détections des points normaux et du bruit (autour de 15%). Les points décalés restent fortement détectés. Les seuils de détection sont les mêmes pour tous les points par manque d'annotations ponctuelles. L'approche peut être améliorée en calibrant un seuil de détection sur les p-valeurs pour chaque point.

6.3.5 Résultats sur la base de test Ω_{Test}

Dans ce chapitre, les résultats sont donnés uniquement sur le patch spécifique de la base \mathcal{B}_1 . Nous ne donnons pas les résultats sur l'ensemble des patchs comme pour les approches précédentes. Les résultats sont présentés sous la forme du taux de détection des points annotés de la base de test de \mathcal{B}_1 à partir de différentes données d'apprentissage du modèle de normalité et sous la forme de représentation visuelle de la détection sur l'ensemble du patch. Les effets du filtrage sont illustrés sur ce dernier résultat.

Taux de détection des points annotés

Le tableau 6.1 contient les taux de détections des différentes classes de points déterminés à partir de différentes données d'apprentissage des modèles de normalité avec matrice d'échelle diagonale et pleine. Les taux de détection des points atypiques sont très satisfaisants (à plus de 80%). De plus les points décalés sont moins détectés par rapport aux approches précédentes, de même pour les autres classes de points normaux. La prise en compte du voisinage directement dans le modèle de normalité basé sur l'estimation de la densité conditionnelle est donc pertinente pour détecter les signatures inusuelles tout en limitant les fausses détections.

Les résultats sur les deux approches sont assez similaires (hormis pour la classe "décalé"), les deux méthodes détectent de manière efficace les points inusuels. Le fait que certains points ne sont pas détectés par l'approche ne signifie pas une impossibilité de détecter les signatures atypiques correspondantes. Les signatures inusuelles consistent en des raies sur les spectrogrammes et constituent donc un ensemble de points à détecter, la détection de la majorité de ces points est suffisante pour détecter les signatures atypiques.

TABLE 6.1 – Taux de détection calculés à partir du modèle de normalité défini par la densité conditionnelle estimée à partir de différentes données d'apprentissage avec matrice d'échelle diagonale et pleine pour les différentes classes de points des données dans Ω_{Test}

Classe de points	Matrice d'échelle diagonale	Matrice d'échelle pleine
Classe "normal"	8.7% \pm 1.4%	12.3% \pm 2.2%
Classe "inusuel"	82.8% \pm 2.1%	80.5% \pm 2.1%
Classe "bruit"	5.6% \pm 1.4%	3.75% \pm 1.4%
Classe "décalé"	84.6% \pm 2.6%	70.8% \pm 2.3%

Résultats visuels de détection sur la base de test Ω_{Test}

Nous représentons sur la figure 6.5 les détections sur l'intégralité des patchs de plusieurs données tests à partir des deux modèles de normalité basés sur la distribution conditionnelle avec et sans filtrage. Le premier patch correspond à un patch normal (1ère ligne), les suivants contiennent différentes signatures atypiques. Il s'agit des mêmes patchs présentant les résultats dans les chapitres précédents (Figure 2.3). Les signatures inusuelles sont bien mises en évidence sur les différents patchs. Pour le patch ne contenant pas de signature inusuelle, les approches détectent principalement la raie N_1 avec quelques points isolés qui sont principalement retirés lors du filtrage par voisinage. La raie N_1 est également détectée sur les patchs atypiques. L'approche basée sur la matrice diagonale semble donner une détection plus forte avec la détection de quelques points voisins des signatures inusuelles mettant plus efficacement en évidence ces signatures, tandis que le modèle de normalité basé sur une matrice d'échelle pleine semble plus focalisé sur la détection des points uniquement sur les raies atypiques. Les deux approches entraînent des détections de nombreux points normaux isolés illustrant la sensibilité des approches aux intensités vibratoires. Ces fausses détections sont en majorité supprimées par le filtrage de voisinage (5.12).

Les temps de calcul des deux approches sont également complètement différents. L'utilisation des matrices diagonales permet d'avoir une formule explicite des p-valeurs à partir de la densité gaussienne, tandis que le calcul des p-valeurs dans le cas des matrices pleines passe par l'estimation de la densité entière. La méthode basée sur l'estimation de densité conditionnelle par noyau en utilisant des matrices diagonales est nettement plus rapide (environ 4 fois plus rapide) et donne des résultats proches de ceux du modèle de normalité utilisant des matrices d'échelle pleines. Dans la suite nous utilisons donc l'estimation de la densité conditionnelle à partir de matrices d'échelle diagonales.

Le modèle de normalité basé sur la densité conditionnelle de chaque point en fonction de tout le voisinage est donc efficace pour détecter les signatures vibratoires atypiques sur les patchs et permet la prise en compte du voisinage dans le modèle directement. Cette approche reste cependant sensible aux intensités vibratoires importantes et entraîne la détection des signatures liées au N_1 également. Malgré un modèle défini à partir du voisinage, l'utilisation du filtre de voisinage reste indispensable pour réduire les fausses détections tout en conservant une bonne mise en évidence des signatures inusuelles.

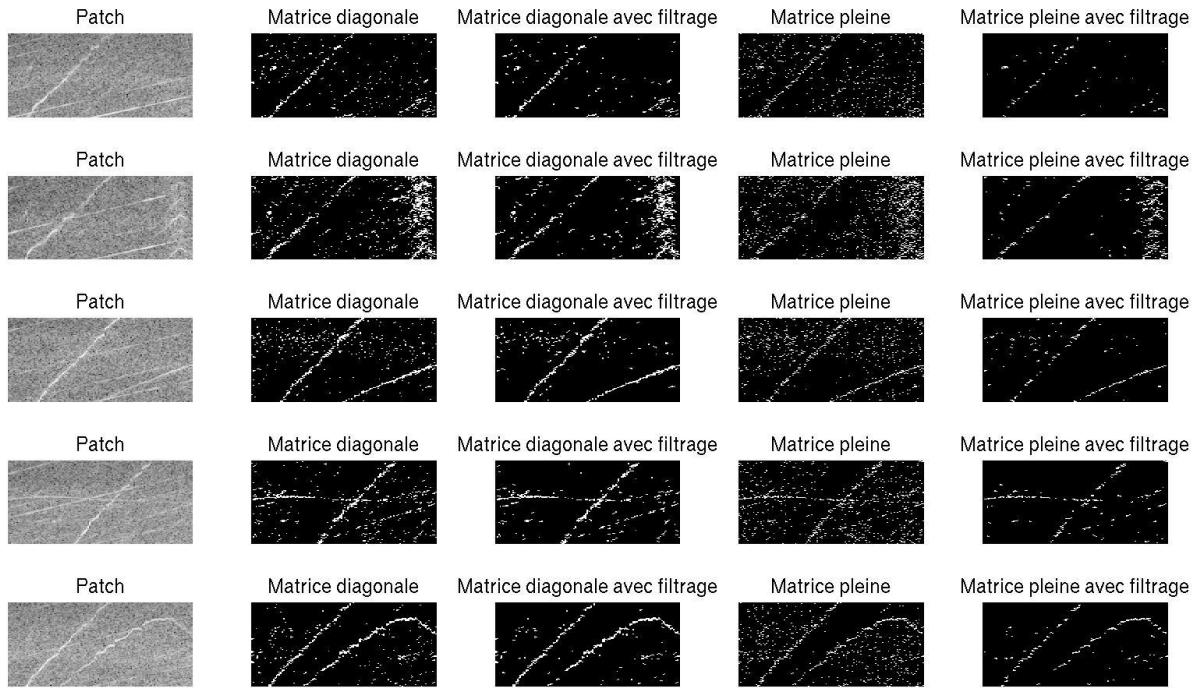


FIGURE 6.5 – Détections sur les patchs entiers à partir du modèle de normalité défini par les distributions conditionnelles des points avec des matrices d'échelles diagonale ou pleine et avec ou sans application du filtrage de voisinage. le premier patch (1ère ligne) correspond est normal, les suivants contiennent différentes signatures inusuelles. Les signatures atypiques sont mises en évidence à partir des deux modèles. Les raies vibratoires liées au N_1 sont également détectées, aucune signature liée au N_2 n'est détectée. Le filtrage de voisinage permet de réduire les fausses détections tout en conservant la détection des signatures atypiques.

6.4 Le modèle de normalité défini à partir du voisinage dans différentes directions

6.4.1 Le voisinage directionnel

Le modèle précédent tenait compte uniformément des voisins du premier ordre autour du point étudié pour trouver les points atypiques. Cependant, les signatures inusuelles que nous cherchons à détecter se présentent sous la forme de raies et ont donc pour attribut une direction. Ainsi en tenant compte de tous les voisins du premier ordre uniformément, nous masquons cette direction et prenons en considération plusieurs points non pertinents (les points voisins n'étant pas dans la direction de la signature inusuelle).

Dans cette section, la direction ainsi que le voisinage sont inclus dans le modèle de normalité. La direction des signatures atypiques n'est pas la même suivant le type d'anomalie sur les spectrogrammes et ne disposant pas d'information a priori sur ces signatures, ou leur localisation, nous étudions les différentes directions possibles pour chaque point. Pour cela, chaque point du

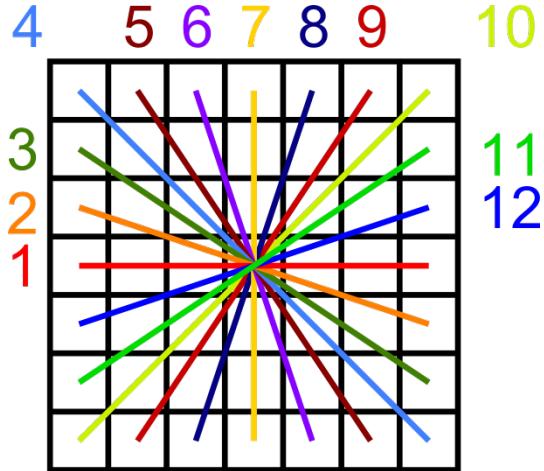


FIGURE 6.6 – Différentes directions linéaires de voisinage possibles en considérant un rayon de voisinage de 3. Chaque valeur correspond à une direction de voisinage. Nous considérons uniquement des voisinages linéaire car nous sommes sur de petites échelles où il est possible de considérer les formes courbes des spectrogrammes comme des droites.

spectrogramme est étudié par rapport à l'ensemble de ses voisins dans différentes directions $\vec{\mathcal{V}}$.

$$\vec{\mathcal{V}}_{f,N_2} = \left\{ \mathcal{V}_{f,N_2}^k, \ k = 1, \dots, \text{card}(\vec{\mathcal{V}}) \right\}$$

$\vec{\mathcal{V}}_{f,N_2}$ correspond à différents voisinages autour du point de coordonnées (f, N_2) suivant différentes directions paramétrées par k (Figure 6.6), et donc \mathcal{V}_{f,N_2}^k correspond au voisinage suivant la direction k . À la différence du voisinage non directionnel étudié dans la section précédente, il est possible de prendre en compte les voisins d'ordre supérieur à 1 car tous les voisins du même ordre ne sont pas pris en compte simultanément. Nous utilisons les voisins d'ordre inférieur ou égal à 3 afin de pouvoir caractériser la structure locale des raies. En prenant en compte les voisins d'ordre maximal 3, nous restons sur de petites échelles, il est donc possible de considérer chaque raie comme une forme linéaire (comme pour les curvelets). Ce niveau de voisinage permet de considérer 12 directions linéaires différentes représentées sur la figure 6.6. Chaque direction considérée prend en compte moins de points que le voisinage direct d'ordre 1 utilisé dans la section 6.3.

6.4.2 Le modèle de normalité

Les différentes directions considérées sont étudiées de manière indépendante. La distribution conditionnelle (6.9) des points le long de chaque direction est estimée à partir de la méthode à noyau appliquée aux données normales des mêmes points. On obtient ainsi un vecteur de densité où chaque composante correspond à la densité conditionnelle estimée dans une des directions de voisinage étudiées.

$$\varphi_{f,N_2}(x, \vec{\mathcal{V}}_{f,N_2}^x) = \left\{ \hat{f}_{f,N_2|\mathcal{V}_{f,N_2}^k}^k(x|\Omega_{App}^{f,N_2}, H_{S\mathcal{V}^k}, H_{\mathcal{V}^k}, \mathcal{V}_{f,N_2}^k) \right\}_{k=1,\dots,12} \quad (6.9)$$